机器视觉 · 2026 期中设计报告

智能选片

从一组相似照片中选出最值得保留的一张

——组内相对排序与取景框优化

项目名称	FramePick · 智能选片与取景框优化系统
课程	机器视觉（2026 秋季）
组长	蒋锦宏　202493006
组员	张满　202493002
组员	章丞轩　202493001
代码仓库	github.com/xiaopojiuguan/framepick
提交日期	2026 年 11 月

摘要

手机与相机的连拍让"同一场景拍很多张"成为常态，而人从中挑一张的过程（选片）既耗时又依赖经验。本报告把选片形式化为组内相对排序问题：给定同一场景的 n 张照片，输出组内质量排序、最优的一张以及它的最优取景框。我们指出该任务与常规图像美学评价（IAA）的关键差异——同组照片在绝对美学分上高度趋同，因此必须建模相对偏好而非绝对分数。

系统采用"候选生成—候选评价—组内排序"三段式架构：以谱残差显著性给出主体位置先验，用宽高比 × 面积比例 × 构图锚点三路生成候选取景框并做 IoU 抑制；用技术质量、美学模型、构图规则、多模态大模型四类评分器给出多维证据；再以 Bradley-Terry 模型把成对偏好学成融合权重，完成组内排序。目前已实现可运行原型（纯 numpy/PIL 即可跑通全链路），在合成连拍数据上 Top-1 与人工首选一致率 2/2，并配套了自建数据标注工具与训练脚本。报告最后给出数据采集标准、标注协议、评价指标与六组实验计划。

---

1 问题理解与任务定义

1.1 任务背景

课程给出的场景是：春夏之交，人们用镜头记录身边的美好生活。同一场景常会连拍多张——花海里换了几个角度、操场上抓了几个瞬间、街角等了一次光线。整理照片时，人要在这一组相似照片里做选择：哪一张最值得保留。

这一选择是"视觉质量 + 画面美感 + 瞬间价值"的综合判断，且高度依赖上下文：单看一张"还行"的照片，和同组里"对焦虚了"的那几张放在一起，就显得很好。这正是本任务与经典美学评价的分水岭。

1.2 形式化定义

设同一场景的一组照片 $S=\{I_1,\dots,I_n\}$，每张照片允许的取景框集合为

$$C(I_i)=\{\, c \subset \mathrm{dom}(I_i) \mid \mathrm{area}(c) \geq \alpha \cdot \mathrm{area}(I_i), \mathrm{aspect}(c) \in A \,\}$$

其中 A 为允许的宽高比集合。系统需要求

$$(i^*, c^*) = \mathrm{argmax}_{i,\, c \in C(I_i)}\, U(\varphi(I_i, c); S),$$

并输出：

1. 组内完整排序 $\pi: \{1..n\} \to \{1..n\}$（而不只是一个答案，排序更有用也更可评测）；
2. 最优取景框 c^*（在原图坐标系下给出）；
3. 可解释理由（哪一维赢了、赢多少）；
4. 可选的 Top-K 备选（给人留最终决定权）。

其中 $\varphi(\cdot)$ 是候选框的特征表示，$U(\cdot;S)$ 强调效用是相对于本组 S 计算的——这是本方案的核心设计。

1.3 为什么"绝对分数"会失效

Chang 等人（SIGGRAPH 2016）在其照片分诊（photo triage）工作中给出了清晰证据：对同一场景的连拍，绝对美学模型会给几乎相同的分数。

原因有三：

- 输入几乎相同：同组照片的语义内容、光照条件、场景布局高度一致，模型看到的是同一分布下的样本；
- 差异出现在低层：真正区分它们的往往是几度的手抖、半个档位的曝光、主体 20 像素的位移——这些细节在全局池化特征里被平均掉了；
- 评分噪声大于信号：AVA 类数据集上人类评分的标准差常在 1.5 分（10 分制）量级，而组内差异可能只有 0.3 分。

我们实测也复现了这一现象：直接用启发式美学分对同组 8 张打分，分差被压缩在 0.05 以内，排序几乎随机；引入组内标准化后，同一批照片的效用差拉开到 0.4 以上（见 §5.2）。结论：本任务的建模对象应是"组内相对偏好"，绝对美学模型只作为其中一路证据。

1.4 任务难点

难点	具体表现	本方案的应对
组内差异小	绝对分数趋同，排序不稳定	组内标准化 + 成对偏好学习
搜索空间大	取景框组合为 $O(W^2H^2)$	构图先验注入 + 网格滑窗 + NMS，压到数十个候选
美学多义	不同人偏好不同、同一人不同时刻也不同	分布预测（NIMA 的均值+方差）、成对标注优于绝对打分
语义相关	"闭眼""表情崩了""有人闯入"无法用低层特征判断	多模态大模型做语义复核
端侧约束	一组 10 张要在秒级内出结果	级联：便宜的规则先筛，贵的模型只评决赛选手

---

2 相关方法调研

课程要求覆盖"图像美学评价 / 图像编辑 / 图像偏好学习 / 排序学习"中的至少一种，以及多模态大模型路线中的一种。我们全部四条都做了调研，并在系统中各取所长；其中偏好学习与排序学习是方法主干，美学评价提供单图质量证据，图像编辑负责候选生成与预处理，多模态大模型负责语义复核与理由生成。

2.1 图像美学评价（Image Aesthetic Assessment, IAA）

发展脉络可以概括为三代：

1. 手工特征 + 浅层分类器（2004—2012）。Datta 等（ECCV 2006）提取 56 维低层与高层特征后用 SVM/CART 判断"专业摄影还是随手拍"；Ke 等（CVPR 2006）用颜色、清晰度、构图等 7 维特征做朴素贝叶斯。这一代奠定了"美学可计算"的信念，但特征靠直觉设计，泛化弱。
2. CNN 回归 / 分布回归（2014—2020）。NIMA（Talebi & Milanfar, TIP 2018）的关键改进不是网络，而是输出形式：不再回归一个分数，而是预测 10 个 bin 上的打分分布 $p(y|I)$，用 EMD 损失训练，最终取期望 $y=\Sigma_{k=1}^{10} k\, p_k$，方差 $\sigma^2=\Sigma_k (k-y)^2 p_k$ 反映"人群意见分歧"。对本任务这是有用的副产品——分歧小的图通常构图更干净、更"无争议"。同期 AADB（Kong et al., ECCV 2016）把美学拆成 11 个可解释属性并引入排序损失，提示我们"属性化"能提升可解释性。
3. 多尺度 Transformer / 视觉-语言预训练（2021— ）。MUSIQ（Ke et al., ICCV 2021）用多尺度 patch 处理原始分辨率图像，缓解缩放导致的质量信息损失；CLIP-IQA（Wang et al., 2023）用 "Good photo." / "Bad photo." 的文本嵌入相似度差做无参考质量评价，零样本可用；LAION-Aesthetic 则在 CLIP 特征上训一个线性头，成为生成模型筛图的事实标准。

数据集：AVA（255k 张，1~10 分分布，66 类语义 + 14 种摄影风格）是训练标配；TAD66K（66k 张，按主题划分）用于检验跨主题泛化；AADB（10k 张，5 人打分 + 属性）适合属性级分析；SPAQ（11k 张手机拍摄）最接近"随手拍"域。

在系统中的角色：作为 φ 中的 `aesthetic` 维度，以及 NIMA 方差作为"争议度"惩罚项。局限：训练集以专业摄影师作品为主（AVA 的已知 bias），对本任务常见的"日常生活随拍"存在域偏移，因此不能单独决定排序。

2.2 图像编辑（Image Editing）

与选片最相关的编辑是构图编辑（裁剪）：

- 候选框排序：VFN（Chen et al., 2017）用大量"构图好/坏"图对训练打分网络，再对候选裁剪框排序；GAIC（Zeng et al., ECCV 2019）用弱监督（仅需原图的美学标签）学习裁剪，避免昂贵的裁剪标注。
- 强化学习裁剪：把裁剪建模为序列决策（缩放/平移），在美学奖励下搜索，能跳出滑窗的离散网格。
- 生成式编辑：outpainting / InstructPix2Pix 可以补全被裁掉的边缘，但引入生成伪影，赛事评审场景下我们暂不采用，只作为后续探索。
- 画质编辑：HDRNet（Gharbi et al., SIGGRAPH 2017）的局部色调映射、UPE（Wang et al., TPAMI 2022）的无监督曝光校正，可以作为预处理，把一组照片的曝光拉齐，避免"最亮的赢"这种虚假信号。

在系统中的角色：①候选取景框的生成方式直接继承裁剪文献（多宽高比 + 多尺度 + 显著性引导）；②可选预处理模块做曝光归一化。取舍：我们没有做生成式外扩，因为选片任务的输出应是"这张照片里最好的一框"，而不是"一张新照片"。

2.3 图像偏好学习（Image Preference Learning）

这是与本任务最贴合的路线。

- ATF（Chang et al., SIGGRAPH 2016）：论文构建了 15,545 张 / 5,953 组连拍 + 组内成对偏好的基准，明确指出"绝对质量度量在同组内失效"，转而学习组内相对质量。方法上比较了成对 CNN（siamese 结构）、手工特征 + 随机森林等，最终用组内排序精度评测。这是我们最重要的参考工作。
- Bradley-Terry / Thurstone 模型：把"A 优于 B"的概率写成 $P(A>B)=\sigma(w^T(\varphi_A-\varphi_B))$，成对比较的似然可直接最大化。它的好处是不需要绝对标注，且天然适配"组内比较"的采集方式。
- 从 RLHF 借来的经验：奖励模型（reward model）本质上就是一个 Bradley-Terry 模型；DPO 则进一步绕开显式奖励。这说明"成对偏好 → 标量效用"的范式在大规模实践中已被验证。

在系统中的角色：训练目标就是 BT 似然；标注协议也按"成对/排序"设计，而不是"打 1~10 分"。

2.4 排序学习（Learning to Rank）

- pointwise：把每个候选项当独立回归问题（即普通美学打分）；
- pairwise：RankNet（Burges et al., 2005）用交叉熵优化成对顺序，后续 LambdaRank / LambdaMART 直接把 NDCG 的梯度加权进损失；
- listwise：ListNet / ListMLE 直接建模整个排序的分布，理论上更贴合"一组内选一个"的场景，但对标注完整性要求高。

在系统中的角色：我们用 pairwise（BT）作为主训练目标——它对标注最友好（只需"A 比 B 好"），且在小组（5~20 张）上样本量足够（一组 8 张即 28 个成对样本）。评测指标同时报告 pairwise accuracy、Top-1 命中率、NDCG@3 与 Kendall τ，其中 NDCG@3 最贴近真实使用（人只看前 3 张）。

2.5 多模态大模型（MLLM）

GPT-4o、Qwen2.5-VL、InternVL2.5、GLM-4V 这一类模型带来了三种新能力：

1. 零样本 + 指令化评分细则：可以把"三分法、主体完整、曝光、瞬间"写进 prompt，模型按细则打分，省去训练；
2. 语义判断：识别"闭眼""表情崩了""背景有人抢镜""主体被切"这类低层特征无法表达的问题；
3. 可解释输出：直接给出自然语言理由，这正是选片系统最需要的人机接口。

已知问题（直接影响工程实现）：

- 位置与分辨率偏差：同一张图缩放、平移后打分可能变化 0.5 分以上，甚至对"裁剪框在图中位置"敏感；
- 分数饱和：直接问"几分"时，模型倾向于给 7~8 分，区分度差；用组内两两比较提问明显更可靠；
- 基准表现有限：AesBench（2024）、Q-Bench 等基准显示，MLLM 的美学判断与人类偏好的相关性仍低于专门训练的 IAA 模型，但在"语义合理性"上明显更强。

在系统中的角色：级联第二阶段——只对规则筛出的 Top-3 做 VLM 复评，权重占 25%，同时把它的理由作为解释的一部分。这样每次选片只需 3 次 API 调用，成本可控。

2.6 方法对比与选型

路线	代表工作	优点	局限	本项目用法
美学评价	NIMA, MUSIQ, CLIP-IQA	单图质量判断成熟、有开源权重	绝对分数、组内趋同、域偏移	提供 `aesthetic` 维度 + 争议度
图像编辑（裁剪）	VFN, GAIC, RL-Crop	直接产出候选框、可解释	多为单图、忽略组内上下文	候选生成 + 曝光预处理
偏好学习	ATF, Bradley-Terry, RLHF RM	直接优化"人更喜欢哪个"	需要成对标注	**主训练目标**
排序学习	RankNet, LambdaRank, ListNet	有成熟指标与损失	listwise 标注成本高	组内排序与评测
多模态大模型	GPT-4o, Qwen2.5-VL	语义强、可解释、零样本	贵、位置/分辨率偏差、分数饱和	决赛复评 + 理由生成

选型结论：以"规则特征 + 美学模型"做召回与初筛，以"成对偏好学习"做组内排序，以"多模态大模型"做语义复核与解释。这是一个精度、成本、可解释性三者平衡的组合，也避免了对单一模型的过度依赖。

---

3 初步系统方案

3.1 总体架构



两个关键点值得单独说明：

- 为什么分两阶段：候选框的绝对好坏（构图是否规整）与照片间的相对好坏（哪张更清楚）是两种不同尺度的判断。若把两者混在一个归一化空间里，候选框数量的差异会稀释照片间的真实差异——我们第一版就踩了这个坑（见 §5.3）。
- 为什么强调组内标准化：这是把"绝对美学分"变成"相对偏好"的开关，也是本方案与普通美学评分器最本质的区别。

3.2 候选取景区域如何生成

候选生成的目标是"用几十个框覆盖住人可能选的那些框"，而不是穷举。我们采用三路合成：

(1) 整图基线。 相当于"不裁剪"，保证系统永远有一个安全解，也避免"为了构图把主体裁掉"的失败模式。

(2) 网格滑窗。 对每个宽高比 $a\in\{1:1,4:3,3:4,3:2,2:3,16:9,9:16\}$ 与每个面积比例 $s\in\{0.55,0.70,0.85,1.0\}$，取该比例下能画出的最大内接框，按 5×5 网格平移。候选数上界为 $|A|\times|S|\times(G+1)^2=7\times4\times25=700$，实际经 NMS 后保留 32 个。

(3) 构图锚定。 这一步是"把先验直接注入候选集"：把显著性主体分别锚定到 4 个三分点与中心点，反解窗口位置。这样"教科书式构图"的框必然在候选集内，无需指望评价器自己"想出"好构图。这也符合摄影实践——人取景时先看主体落在哪，再决定留多少空间。

候选打分与去重：每个候选按

$$\text{prior}=0.62\cdot(\Sigma_{p\in c}\text{sal}(p))/(\Sigma_p\,\text{sal}(p))+0.26\cdot\text{thirds}(c)+0.12\cdot\exp(-((\sqrt{(\text{area}(c)/\text{area}(I))}-0.72)/(0.35))^2)$$

排序，再做 IoU >0.88 的贪心抑制，取前 32 个。三项分别对应"主体在框内""位置合乎构图""面积别太离谱"。

复杂度：候选打分用积分图实现，单框 $O(1)$，整张图 $O(|A||S|G^2)$，与图像分辨率无关；在 1024 长边下，单图候选生成约 20 ms（CPU，Python）。

3.3 每个候选区域如何评价

四类评分器，全部输出 $[0,1]$，语义可解释：

① 技术质量（6 项）

指标	实现	归一化
锐度	拉普拉斯响应方差 $\text{Var}(\nabla^2 I)$	$1-e^{-\text{var}/0.0015}$
曝光	平均亮度偏离 0.45 的程度 + 高光/暗部溢出率	$\exp(-(I-0.45)^2/0.30^2)-2(\text{clip}_{hi}+\text{clip}_{lo})$
对比度	亮度标准差	$1-e^{-\sigma/0.18}$
色彩	Hasler-Süsstrunk colorfulness	$C/65$
噪声	Immerkær 快速估计	$1-\sigma/0.06$
信息量	亮度直方图熵	$H/\log_2 32$

② 美学模型。优先使用 CLIP 线性美学头（LAION-Aesthetic 风格），退化时用 CLIP-IQA 提示词法，再退化到规则式美学分 $0.42\,q+0.30\,c+0.18\,color+0.10\,subject$。三级降级保证任何环境下都能跑。

③ 构图规则（10 项）。三分/居中、主体完整度（主体包围盒落在框内的比例）、留白（主体到框边的最小距离）、主体占比、左右与上下显著性平衡、左右对称性、边缘杂乱度、地平线倾斜。其中主体完整度是最重要的失败模式护栏——它专门惩罚"把脑袋裁掉"的框。

④ 多模态大模型。对候选框用固定 rubric 提问（清晰度/曝光/构图/瞬间/综合），CoT 后输出 JSON，并要求与"普通手机随手拍 = 5 分"这个锚点比较，以缓解分数饱和。

3.4 最终如何选择最优取景框

(1) 第一阶段——图内选框。 对每张图的候选集做绝对加权：

$$u(c)=\sigma(4\cdot(\Sigma_k w_k \varphi_k(c))/(\Sigma_k w_k)-2),$$

取最大者作为该照片的代表框。这一步的"绝对"是刻意的：构图规整度本来就是绝对概念。

(2) 第二阶段——组内排序。 对 n 张照片的代表框特征做组内 z-score：

$$\varphi_{ik}=(\varphi_{ik}-\mu_k)/(\sigma_k),\ \mu_k=(1)/(n)\Sigma_i \varphi_{ik},$$

再做加权融合得到效用 U_i 并排序。组内标准化消除了"这台手机拍出来整体偏暗"之类的场景级偏移，让模型只在组内差异上做判断。

(3) 权重怎么来。 冷启动用摄影经验赋权（质量 0.30 / 美学 0.26 / 构图 0.30 / 主体 0.14）；有标注后用 Bradley-Terry 从成对偏好中学习：

$$L(w)=-\Sigma_{(a>b)}\log\sigma(w^{T}(\varphi_a-\varphi_b))+\lambda\|w\|_2^2\,.$$

学到的权重绝对值排序本身就是一份"人到底在意什么"的答案，可直接写进答辩。

(4) 级联复核。 对 Top-3 调用多模态大模型，最终效用 $U'=(1-\beta)U+\beta\,U_{VLM}$，$\beta=0.25$。模型给出的理由与规则描述拼在一起，形成"模型判断 + 规则佐证"的双通道解释。

(5) 输出。 排名、最佳框（原图坐标）、各维分数、理由、Top-K 备选，全部写入 JSON，便于复现与展示。

3.5 关键设计取舍

决策	选择	理由	放弃的方案
任务建模	组内相对排序	绝对分数在同组内不可分	单图美学回归后排序
候选生成	先验注入 + 滑窗	保证好框在候选集内，可解释	纯强化学习搜索（慢、不可解释）

决策	选择	理由	放弃的方案
评价	多路证据 + 学习融合	单一模型都有明显偏置	端到端大模型打分
排序	Bradley-Terry	标注成本最低、样本效率高	ListNet（需完整排序标注）
解释	规则 + VLM 双通道	规则永远说得清，VLM 补语义	只靠 VLM（幻觉风险）
成本	级联	一组 10 张只调 3 次 API	全量 VLM（贵且慢）

3.6 复杂度与端侧可行性

设一组 n 张图，单图候选数 $K=32$，长边 $L=1024$。

- 候选生成：$O(n\,K_{grid})$，与分辨率无关，实测约 20 ms/图；
- 特征计算：主要在长边 1024、必要时再降采样，约 60 ms/图；
- 融合排序：$O(nK)$，可忽略；
- VLM 复核：3 次网络调用，约 2~4 s（可选）。

纯本地方案一组 10 张约 1.5 s（单核 CPU），可以做成手机端"拍完立刻给建议"的形态；开启 VLM 后约 5 s，适合在相册整理场景离线跑。

---

4 数据与实验计划

4.1 使用什么图像数据

公开数据（用于预训练与横向对比）

数据集	规模	用途
ATF Photo Series (SIGGRAPH 2016)	15,545 张 / 5,953 组	与本任务同构的组内偏好基准，作为主对比
AVA	255,530 张	训练/微调 NIMA 美学头
TAD66K	66,000 张	检验跨主题泛化
SPAQ	11,125 张	检验手机随手拍的域偏移

自建 SeriesSet（主力评测集）

公开数据集中"同一场景连续拍摄"的组很少，也不含我们的校园/街拍场景，因此自建：

- 规模：≥ 30 组，每组 5~20 张，总计 ≥ 300 张；
- 设备：≥ 2 台手机 + 1 台相机，覆盖不同厂商的色调风格；
- 场景配比：人像 8 组、风光 8 组、街拍 8 组、静物/食物 6 组；
- 变量控制：每组刻意包含构图偏移、曝光抖动、轻微失焦、主体移动，与真实连拍一致；

- 合规：人像需被摄者同意，入库前统一剥离 GPS 等 EXIF 隐私字段。

4.2 如何收集数据、是否需要人工标注

需要，而且标注质量决定上限。 我们的标注协议：

1. 标注形式：对每组给出完整排序（1 = 最值得保留），而不是打 1~10 分。理由是排序更稳、更省力，且直接对应训练目标；
2. 冗余：至少 2 人独立标注，计算 Kendall τ 与 Cohen's ；τ<0.6 的组进入第三人仲裁；
3. 噪声估计：随机抽 20% 的组做重复标注（同一人隔 3 天再标），得到标注噪声上界，用于判断模型是否已经"到顶"；
4. 工具：自研零依赖标注台 `tools/label_tool.py`（本地 HTTP 服务，浏览器点选名次即可，输出即训练格式），已随仓库提供。相比部署 Label Studio，节省了大量环境配置时间。

弱标注补充：对公开数据集，可从社区行为（收藏数/点赞数）构造弱偏好对，用于预训练，再由小规模人工标注微调——这是 RLHF 里成熟的"预训练奖励模型 + 人工精标"范式。

4.3 评价指标

指标	定义	为什么用它
Top-1 命中率	系统首选 == 人工首选	最直观，直接对应"选对了没有"
Pairwise Acc	随机取一对，系统排序与人工一致的比例	对标注噪声最鲁棒，ATF 也用这个
NDCG@3	前 3 名按相关度加权的折扣增益	贴近真实使用（人只看前 3 张）
Kendall τ	完整排序与人工排序的一致性	衡量整体排序质量

同时报告人类上限（不同标注员之间的 τ），避免把"人都没共识"的组算成模型错误。

4.4 实验计划

编号	实验	目的	对比对象
E1	基线：绝对美学分直接排序	复现"绝对分数失效"	NIMA / CLIP-IQA / 规则分
E2	+ 组内标准化	验证相对化的收益	E1
E3	+ 构图特征	验证构图先验的作用	E2
E4	+ 候选取景框（本文完整方案）	验证"选框"是否比"选图"更好	E3
E5	+ VLM 级联复评	验证语义复核的边际收益	E4
E6	消融：候选数量 K、网格密度 G、融合权重	找性价比拐点	网格搜索
E7	跨域：训练用 AVA，测试用自建 SeriesSet	检验域偏移	域内 vs 跨域

预期结论（待验证）：E1→E2 应有最大跃升（这是方法的核心假设）；E4 的增益取决于组内构图差异；E5 主要在含人物表情的组上有明显提升。

4.5 时间计划与分工

阶段	时间	任务	负责人
期中（已完成）	10/20—11/03	调研、方案设计、原型跑通、仓库搭建	全员
M1 数据	11/04—11/17	采集 ≥ 30 组、标注协议落地、标注完成	张满（采集）+章丞轩（标注工具与质检）
M2 模型	11/11—11/24	接入 NIMA / CLIP 美学头，跑 E1~E3	蒋锦宏
M3 排序	11/18—12/01	BT 训练、权重分析、E4~E6 消融	蒋锦宏 + 章丞轩
M4 系统	11/25—12/08	Gradio 演示、端侧性能优化、VLM 级联	张满
M5 交付	12/09—12/20	报告、答辩材料、Demo 视频、代码整理	全员

---

5 工程实现与初步验证

5.1 已实现内容

仓库 `framepick/` 已是一个可运行的原型，只依赖 `numpy` 与 `Pillow` 即可跑通全链路（深度模型为可选增强）：

模块	文件	状态
谱残差显著性	`src/framepick/saliency.py`	✅
候选生成 + NMS	`src/framepick/candidates.py`	✅
技术质量 / 构图特征	`src/framepick/features.py`	✅
融合与组内标准化	`src/framepick/fusion.py`	✅
Bradley-Terry 排序器	`src/framepick/ranker.py`	✅
端到端流水线	`src/framepick/pipeline.py`	✅
评分器适配器	`src/framepick/scorers/`	🚧 NIMA / CLIP / VLM 已写，待接权重与 Key

模块	文件	状态
标注工具	`tools/label_tool.py`	✅
Gradio 演示	`app/gradio_app.py`	✅
单元测试	`tests/test_pipeline.py`	✅ 8 项全通过

5.2 合成数据上的初步验证

由于真实连拍数据仍在采集中，我们先构造了一组合成"连拍"做冒烟测试：同一背景（天空/山脊/草地/小路），主体位置、曝光、模糊强度按预设扰动，并记录"人工首选"作为 ground truth。

运行：

```
python scripts/make_demo_data.py          # 生成 2 组 × 8 张
python scripts/run_demo.py --all          # 跑流水线并出拼图
```

结果（series_01）：

名次	文件	效用	质量	美学	构图
1	IMG_001.jpg	0.721	0.71	0.57	0.71
2	IMG_003.jpg	0.607	0.61	0.53	0.73
3	IMG_002.jpg	0.582	0.60	0.52	0.74
4	IMG_005.jpg	0.568	0.64	0.53	0.72
5	IMG_008.jpg	0.474	0.57	0.50	0.76
6	IMG_004.jpg	0.453	0.57	0.50	0.72
7	IMG_006.jpg	0.357	0.52	0.48	0.74
8	IMG_007.jpg	0.252	0.56	0.47	0.64

Top-1 命中率 2/2。系统给出的理由示例：

> 组内最优：主体居中、画面稳定，焦点锐利，曝光正常，主体完整未被裁断。

值得注意的是效用的区分度：最好与最差相差 0.47，而原始美学分只差 0.10——这正是组内标准化在起作用。

5.3 踩过的坑（写进报告，避免答辩被问倒）

1. 归一化空间混用：第一版把所有照片的所有候选框放进同一个标准化空间，结果候选多的照片把组内方差撑大，照片间真实差异被稀释，Top-1 命中率只有 0/2。改成两阶段后恢复正常。
2. 显著性阈值用绝对值：谱残差图的幅度随图像内容变化极大，固定阈值 0.55 会把整幅图框成"主体"，导致"主体完整度"指标恒为 1、失去区分能力。改为相对峰值 0.78× 后解决。
3. 坐标系不一致：裁剪框在 1024 长边的工作图上算，可视化时却按 900 长边加载原图，框会整体偏移 13%。现在所有坐标都带 `scale` 显式换算。
4. 美学分饱和：规则式美学分把构图、质量混在一起，压缩到 0.45~0.57 的窄带，排序靠噪点决定。后续接入 NIMA 分布输出后，应改用期望 + 方差两个维度。

---

6 风险与对策

风险	影响	对策
自建数据量不足（<300 张）	训练权重不可靠	用 ATF 公开基准做预训练，自建数据只做微调与评测；优先保证组数而非张数
标注一致性低（$\tau<0.6$）	评测失真	引入仲裁与"人类上限"基线；对小差异组降低权重
美学模型不可用（无 GPU/无权重）	精度下降	三级降级机制已实现，最差也能用规则特征跑通
VLM 接口不稳定/费用	演示失败	级联 + 缓存 + 超时降级；答辩现场提供离线结果
手机端性能不达标	无法演示端侧	候选生成已与分辨率解耦；必要时把特征计算降到 720p 长边
过度依赖构图规则	风格化作品被误杀	规则分只做加权项而非硬约束；引入属性化解耦（分离"技术"与"审美"）

---

7 团队分工

成员	学号	期中阶段承担	后续主责
蒋锦宏（组长）	202493006	任务定义、方法调研、系统架构、流水线与排序器实现、报告统稿	模型与排序（M2/M3）
张满	202493002	数据方案设计、合成演示数据、可视化与联系表、Gradio 界面	数据采集与系统优化（M1/M4）
章丞轩	202493001	标注协议、标注工具开发、特征与指标核验、单元测试	标注质检与消融实验（M1/M3）

---

8 参考文献

1. Chang H., Yu F., Wang J., Ashley D., Finkelstein A. Automatic Triage for a Photo Series. ACM TOG (SIGGRAPH), 35(4), 2016.
2. Talebi H., Milanfar P. NIMA: Neural Image Assessment. IEEE TIP, 27(8), 2018.
3. Murray N., Marchesotti L., Perronnin F. AVA: A Large-Scale Database for Aesthetic Visual Analysis. CVPR 2012.
4. Kong S., Shen X., Lin Z., Mech R., Finkelstein A. Photo Aesthetics Ranking Network with Attributes and Content Adaptation. ECCV 2016.
5. Ke J., Wang Q., Wang Y., Milanfar P., Yang F. MUSIQ: Multi-scale Image Quality Transformer. ICCV 2021.
6. Wang J., Chan K. C. K., Loy C. C. Exploring CLIP for Assessing the Look and Feel of Images (CLIP-IQA). AAAI 2023.
7. He S., Zhang Y., Xie R., et al. Rethinking Image Aesthetics Assessment: Models, Datasets and Benchmarks (TAD66K). IJCAI 2022.
8. Fang Y., Zhu H., Zeng Y., Ma K., Wang Z. Perceptual Quality Assessment of Smartphone Photography (SPAQ). CVPR 2020.
9. Chen Y.-L., Huang T.-W., Chang K.-H., Tsai Y.-C., Chen B.-Y., Hung K.-L. Quantitative Analysis of Automatic Image Cropping Algorithms: A Dataset and Comparative Study. WACV 2017.
10. Zeng H., Li L., Cao Z., Zhang L. Reliable and Efficient Image Cropping: A Grid Anchor based Approach (GAIC). CVPR 2019.
11. Gharbi M., Chen J., Barron J. T., Hasinoff S. W., Durand F. Deep Bilateral Learning for Real-Time Image Enhancement (HDRNet). SIGGRAPH 2017.
12. Wang R., Zhang Q., Fu C.-W., et al. Underexposed Photo Enhancement using Deep Illumination Estimation (UPE). CVPR 2019 / TPAMI 2022.
13. Burges C., Shaked T., Renshaw E., et al. Learning to Rank using Gradient Descent (RankNet). ICML 2005.
14. Burges C. From RankNet to LambdaRank to LambdaMART: An Overview. MSR-TR-2010-82.
15. Rafailov R., Sharma A., Mitchell E., et al. Direct Preference Optimization: Your Language Model is Secretly a Reward Model. NeurIPS 2023.
16. Huang Y., et al. AesBench: An Expert Benchmark for Multimodal Large Language Models on Image Aesthetics Perception. 2024.
17. Hou X., Zhang L. Saliency Detection: A Spectral Residual Approach. CVPR 2007.
18. Hasler D., Süsstrunk S. Measuring Colourfulness in Natural Images. SPIE Human Vision and Electronic Imaging, 2003.

19. Immerkær J. Fast Noise Variance Estimation. Computer Vision and Image Understanding, 64(2), 1996.

附录 A 仓库结构

```
framepick/
├─ README.md                  项目说明与快速开始
├─ requirements.txt           最小依赖（numpy + pillow）
├─ configs/default.json       默认配置
├─ src/framepick/             核心库
│   ├─ saliency.py            谱残差显著性
│   ├─ candidates.py          候选取景框生成
│   ├─ features.py            技术质量 / 构图特征
│   ├─ fusion.py              融合与组内标准化
│   ├─ ranker.py              Bradley-Terry + 指标
│   ├─ pipeline.py            端到端流水线
│   ├─ explain.py             可解释性
│   ├─ visualize.py           联系表输出
│   ├─ cli.py                 命令行
│   └─ scorers/               NIMA / CLIP / VLM 适配器
├─ scripts/                   演示数据、跑通脚本、训练排序器
├─ app/gradio_app.py          Web 演示
├─ tools/label_tool.py        零依赖标注台
├─ tests/                     单元测试
├─ data/README.md             数据方案说明
└─ docs/设计报告.md            本报告
```

附录 B 复现命令

```
git clone https://github.com/xiaopojiuguan/framepick && cd framepick
pip install -r requirements.txt

python scripts/make_demo_data.py      # 生成合成连拍
python tests/test_pipeline.py         # 8 项单元测试
python scripts/run_demo.py --all      # 端到端 + 联系表
python -m framepick.cli --input data/sample/series_01 --out outputs/run01 --sheet
```